جامعة بجاية
Tasdawit n Bgayet
Université de Béjaïa

Université de béjaia
Faculté des sciences exactes
Département Informatique

Module : Concepts avancés de BD
Dr S. Chabane - Mechiouri

ING 4 : GL 2026/2027

Mini-projet : Réseau de capteurs environnementaux

Livrables du miniprojet : Les livrables finaux seront compressés et chargés dans l'espace cours.

- **Les scripts SQL**, numérotés dans l'ordre d'exécution (`01_schema.sql`, `02_referentiel.sql`, etc.). Exécutés dans cet ordre sur une installation vierge, ils doivent reconstruire l'ensemble du projet sans erreur : les trois bases, le chargement et les requêtes du rapport.
- **Un rapport** de dix pages au maximum, organisé selon les trois étapes. Il présente vos choix de conception, répond aux questions de chaque étape et donne les résultats obtenus (nombre de mesures chargées et isolées, extraits du rapport XML, plans d'exécution commentés). Il ne recopie pas les scripts.

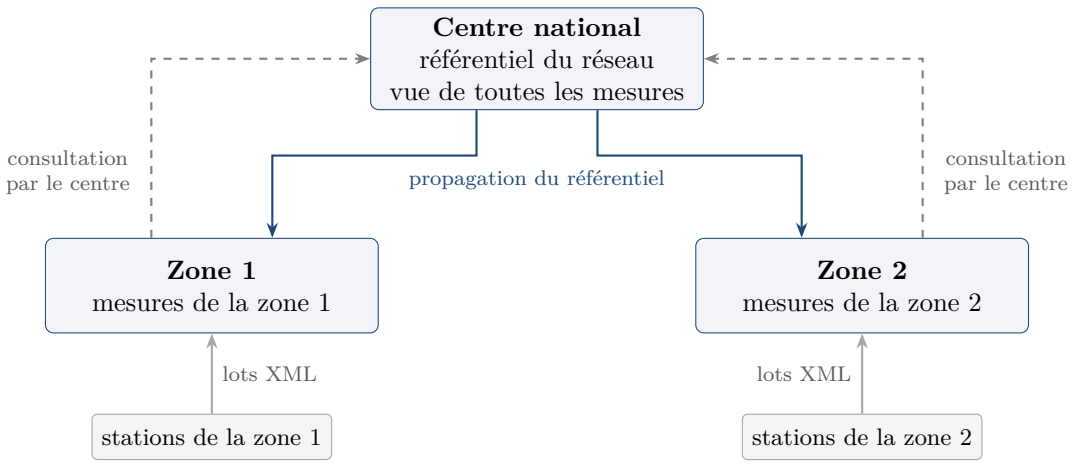
Évaluation : Travail continu : 50 %. Démonstration et livrables : 50 %.

1. Le contexte

Un organisme national de surveillance de l'environnement exploite un réseau de stations de mesure installées dans quatre wilayas, regroupées en deux zones. Chaque station porte plusieurs capteurs : un capteur de température, un capteur de qualité de l'air, et un troisième capteur dont la nature dépend de votre variante. Tous partagent les mêmes informations de base (un code, une station de rattachement, une date de mise en service, un état), mais chacun mesure des grandeurs qui lui sont propres.

Chaque nuit, les stations envoient les mesures de la journée sous forme de lots XML. Ces données ne sont pas parfaites : un capteur défaillant peut transmettre une valeur impossible, un champ peut manquer, un lot peut être renvoyé deux fois.

Pour des raisons de volume et d'autonomie, chaque zone conserve ses propres mesures sur son propre serveur. Le centre national, lui, définit le référentiel du réseau (stations, capteurs, seuils d'alerte) et doit pouvoir travailler sur l'ensemble des mesures comme si elles se trouvaient dans une seule base.



Votre travail consiste à concevoir et à réaliser la base de données de ce réseau avec PostgreSQL. Il se déroule en trois étapes : le modèle relationnel-objet, les échanges XML et la distribution des données.

2. Les données du réseau

Stations et capteurs : Chaque wilaya compte trois stations. Une station est identifiée par un code formé du préfixe de la wilaya et d'un numéro (par exemple `BJ-01` pour la première station de Béjaïa). Elle a un nom, une wilaya, une zone (1 ou 2) et une position (latitude, longitude, altitude). Chaque station porte trois capteurs, dont le code prolonge celui de la station : `BJ-01-T1` pour la température, `BJ-01-A1` pour la qualité de l'air, et une troisième lettre pour le capteur spécifique de la variante.

Grandeurs mesurées : Chaque capteur relève ses grandeurs toutes les trois heures (0 h, 3 h, 6 h, . . ., 21 h).

Capteur	Grandeurs	Unités
Température	température de l'air	°C
Qualité de l'air	particules PM2.5, particules PM10, dioxyde d'azote NO_2	µg/m^3
Hydrométrie (variante A)	humidité relative ; pluie tombée depuis la mesure précédente	% ; mm
Sonomètre (variante B)	niveau sonore	dB(A)
Anémomètre (variante C)	vitesse du vent ; direction du vent (0 à 359)	m/s ; degrés

Fichiers fournis : Les fichiers sont disponibles sur l'espace cours, chaque binôme téléchargera la variante qui correspond à son choix :

- `stations_X.csv` : les douze stations avec leur position et leur zone ;
- `capteurs_X.csv` : les trente-six capteurs avec leur station, leur type, leur date de mise en service, leur date de retrait (vide pour un capteur toujours en service) et leur état ;
- `seuils_X.csv` : les seuils d'alerte, chacun défini par un type de capteur, une grandeur, une borne (minimum ou maximum), une valeur et une unité ;
- `lots_X.xml` : les lots de mesures du 1er janvier au 30 avril 2026, soit un lot par station et par jour.

Les trois fichiers CSV forment le référentiel initial du réseau. Ils sont encodés en UTF-8, commencent par une ligne d'en-tête et contiennent une seule valeur simple par colonne : la position d'une station, par exemple, y occupe trois colonnes (latitude, longitude, altitude). C'est à vous de passer de ce format plat à votre modèle relationnel-objet. Le fichier XML représente ce que les stations ont réellement transmis.

Qualité des données : Le fichier de lots contient des erreurs, comme un vrai flux de capteurs. Vous rencontrerez cinq sortes de problèmes :

- **valeur impossible** : une grandeur qui ne peut pas exister physiquement (humidité supérieure à 100 %, concentration négative, valeur d'erreur d'un capteur défaillant) ;
- **valeur manquante** : une grandeur attendue absente de la mesure ;
- **format invalide** : un nombre ou une date qui ne peut pas être lu tel quel ;
- **capteur inconnu** : une mesure attribuée à un capteur absent du référentiel ;
- **doublon** : une mesure déjà reçue, renvoyée une seconde fois par la station.

Par ailleurs, un capteur peut être mis en service ou retiré pendant la période ; les dates correspondantes figurent dans le référentiel. Ce n'est pas une erreur, mais vos requêtes doivent en tenir compte.

3. Le travail demandé

3.1. Modéliser le réseau

Cette première étape porte sur le schéma du centre national, avant toute question de distribution. Le but est d'exploiter les mécanismes relationnels-objet plutôt que de produire un schéma relationnel classique.

Ce qui est attendu :

- **Des objets composés.** La position d'une station, ou une mesure de qualité de l'air avec ses trois composantes, forment un tout. Elles doivent être représentées comme une seule valeur structurée, manipulable d'un bloc, et non comme des colonnes sans lien entre elles.
- **Une hiérarchie de capteurs.** Tous les capteurs partagent les mêmes informations communes ; chaque type de capteur ajoute les siennes. Votre schéma doit refléter ce lien de généralisation : interroger « les capteurs » doit donner tous les capteurs, quel que soit leur type.
- **Un schéma qui se protège seul.** Une valeur physiquement impossible doit être refusée par la base elle-même, au moment de l'insertion, sans dépendre de l'application. De même, une mesure ne peut concerner qu'un capteur qui existe, quel que soit son niveau dans la hiérarchie.
- **Des opérations définies dans la base.** Au minimum : la distance en kilomètres entre deux stations, le test qui indique si une mesure dépasse un seuil du référentiel, et une conversion d'unité adaptée à votre variante (par exemple de m/s en km/h, ou de °C en °F). Ces opérations doivent s'appliquer directement aux objets que vous avez définis.

Questions à traiter dans le rapport. Pourquoi avoir regroupé telle information dans un type plutôt que dans plusieurs colonnes ? Votre hiérarchie garantit-elle réellement l'intégrité des mesures, et comment l'avez-vous vérifié ? Qu'est-ce que la syntaxe Oracle vue en cours aurait permis d'écrire plus simplement, et qu'avez-vous dû faire autrement avec PostgreSQL ?

À la fin de cette étape, le référentiel fourni est chargé dans votre schéma, l'insertion d'une mesure pour un capteur inexistant ou d'une valeur impossible est refusée, et les opérations demandées s'utilisent dans une requête SQL.

3.2. Faire entrer les données

Cette étape relie la base au monde extérieur, dans les deux sens : lire les lots envoyés par les stations, et produire un document XML destiné à d'autres systèmes.

Ce qui est attendu :

- **Un chargement entièrement en SQL.** Le fichier de lots est lu et intégré par des requêtes SQL, sans programme ni script externe (pas de Python, pas de conversion préalable du fichier).
- **Aucune mesure perdue.** Chaque mesure du fichier doit se retrouver soit dans les tables de mesures, soit dans un espace d'isolement qui conserve sa forme d'origine, son lot et le motif de son rejet (l'une des cinq sortes de problèmes décrites plus haut). La présence d'erreurs ne doit pas faire échouer le chargement des mesures correctes. Le nombre de mesures valides plus le nombre de mesures isolées doit être égal au nombre de mesures du fichier.
- **Des lots bruts interrogeables.** Les lots sont aussi conservés au format XML d'origine, et l'on doit pouvoir les interroger directement, sans passer par les tables de mesures. Au minimum : retrouver les lots qui contiennent une mesure d'un capteur donné, et compter les mesures de chaque lot.
- **Un rapport XML produit par la base.** Une requête génère le rapport décrit pour votre variante (section 4), pour une période donnée en paramètre. Vous proposez la structure du document (éléments, attributs, imbrication) et vous la justifiez.

Questions à traiter dans le rapport. Comment votre chargement réagit-il si l'on ajoute au fichier une mesure contenant une erreur que vous n'avez pas prévue ? Comment distinguez-vous un doublon d'une nouvelle mesure ? Pourquoi conserver les lots bruts alors que les mesures sont déjà en tables ?

À la fin de cette étape, le fichier est chargé, chaque mesure est soit en base soit isolée avec son motif, les deux comptes s'additionnent au total du fichier, et le rapport XML est généré par une requête.

3.3. Répartir sans perdre la vue d'ensemble

Jusqu'ici, tout tenait dans une seule base. Cette dernière étape répartit les données comme dans le réseau réel.

Les trois bases : Vous créez trois bases distinctes, nommées `centre`, `zone1` et `zone2`.

- `centre` contient le référentiel complet. C'est la seule base où le référentiel est modifié. Elle ne stocke elle-même aucune mesure, mais elle donne accès à toutes.
- `zone1` et `zone2` stockent chacune les mesures de leur zone, et seulement celles-là. Elles disposent d'une copie du référentiel, nécessaire pour contrôler localement leurs mesures.

Ce qui est attendu :

- **Une organisation temporelle.** Dans chaque zone, les mesures sont organisées par période (mois ou semaine selon votre variante), de sorte qu'une requête sur une période ne parcoure que les données de cette période.
- **La transparence pour le centre.** Depuis `centre`, une seule requête SQL consulte les mesures de tout le réseau, comme si elles étaient locales. Une mesure insérée depuis `centre` est stockée physiquement dans la bonne zone, sans que l'utilisateur ait à préciser laquelle.
- **Un référentiel propagé.** Un ajout ou une modification du référentiel dans `centre` (une nouvelle station, un capteur qui change d'état) apparaît automatiquement dans les deux zones, sans ressaisie.
- **Des identifiants uniques sur tout le réseau.** Deux mesures ne peuvent jamais porter le même identifiant, même si elles sont créées indépendamment dans deux zones différentes.
- **Le rapport XML depuis le centre.** Le rapport de l'étape précédente doit fonctionner depuis `centre`, sur les données réparties.

Questions à traiter dans le rapport. Que se passe-t-il, concrètement, quand le centre exécute une requête sur une seule zone et un seul mois ? Montrez-le avec les plans d'exécution. Que deviennent les requêtes du centre si une zone est indisponible ? Quelles modifications du référentiel sont propagées, et lesquelles ne le sont pas ?

À la fin de cette étape, le centre interroge et alimente tout le réseau de façon transparente, un capteur ajouté au centre apparaît dans les deux zones, et le rapport XML est produit depuis le centre.

4. Votre variante

Chaque binôme reçoit une variante. Le cœur du travail est identique ; les données, le capteur spécifique, l'organisation temporelle et le rapport à produire changent.

	Variante A	**Variante B**	**Variante C**
Zone 1	Béjaïa, Jijel	Alger, Blida	Oran, Mostaganem
Zone 2	Sétif, Bordj Bou Arréridj	Tizi Ouzou, Bouira	Tlemcen, Sidi Bel Abbès
Capteur spécifique	Hydrométrie : humidité relative et pluie	Sonomètre : niveau sonore	Anémomètre : vitesse et direction du vent
Organisation des mesures dans le temps	Par mois	Par semaine	Par mois
Format des lots	Mesures à plat, valeurs en attributs	Valeurs en éléments, avec espace de noms	Imbrication station, capteur, mesure

Le rapport XML de chaque variante :

- **Variante A, bilan journalier.** Pour chaque jour de la période, chaque station et chaque grandeur mesurée : le minimum, le maximum et la moyenne des mesures valides, ainsi que le nombre de mesures utilisées.
- **Variante B, dépassements de seuils.** Pour chaque capteur et chaque grandeur qui a un seuil dans le référentiel : le nombre de mesures qui dépassent ce seuil sur la période, et les instants du premier et du dernier dépassement. Les capteurs sans dépassement apparaissent avec un nombre nul.
- **Variante C, variabilité.** Pour chaque zone et chaque type de capteur : les N capteurs dont les mesures ont le plus varié sur la période, classés du plus variable au moins variable, N étant un paramètre. Vous choisissez et justifiez la grandeur retenue pour chaque type et votre mesure de la variabilité.

Un extrait de chaque format de lot figure en annexe (Fichier Annexe variantes).